

종합 실습과제 · 주택가격 데이터 분석 파이프라인

Python 시각화 · 다중공선성 진단 · Orange 회귀 · Power BI · HTML 대시보드 · Ollama 연동

데이터셋: Ames Housing (housePricing_reduced.csv) · 배점 합계 100점

0. 과제 개요

본 과제는 하나의 주택가격 데이터셋으로 **데이터 탐색 → 다중공선성 제거 → 모델링 → BI 시각화 → 웹 대시보드 → LLM 연동**까지 이어지는 엔드-투-엔드 분석 파이프라인을 직접 구축하는 것을 목표로 한다. 각 과제는 앞 과제의 결과를 다음 과제에서 재사용하도록 설계되어 있다.

원본 Ames Housing 데이터는 feature가 80개로 실습에 과도하므로, **SalePrice와의 상관·설명력·결측 비율을 근거로 16개 핵심 feature로 감축**한 파일(housePricing_reduced.csv)을 사용한다. 감축 근거는 아래 1장에 정리한다.

1. 데이터셋 안내 (감축 근거 포함)

1.1 감축 요약

구분	원본	감축본(제공 파일)
행(관측치)	1,460	1,460
Feature 수	80개	16개 + target
컬럼 총계	81 (Id·SalePrice 포함)	18 (Id·SalePrice 포함)
결측치	다수(최대 99.5%)	없음(선별로 제거)

감축 원칙: ① SalePrice와 상관이 약한 feature 제외, ② 결측 50% 이상 컬럼

(PoolQC·MiscFeature·Alley·Fence 등) 제외, ③ 다만 다중공선성 실습이 가능하도록 **서로 중복되는 강 상관 쌍은 의도적으로 남겨 둠** (과제 2의 학습 대상).

1.2 Feature 사전 (제공 16 개 + Target)

컬럼	의미	유형
OverallQual	전반적 자재·마감 품질 (1~10)	수치(순서)
GrLivArea	지상 거주 면적 (sq ft)	수치
GarageCars	차고 수용 차량 대수	수치
GarageArea	차고 면적 (sq ft)	수치
TotalBsmntSF	지하 전체 면적 (sq ft)	수치
1stFlrSF	1층 면적 (sq ft)	수치

컬럼	의미	유형
FullBath	지상 전체 욕실 수	수치
TotRmsAbvGrd	지상 방 개수(욕실 제외)	수치
YearBuilt	건축 연도	수치
YearRemodAdd	리모델링 연도	수치
Fireplaces	벽난로 수	수치
LotArea	대지 면적 (sq ft)	수치
Neighborhood	지역(동네) 이름	범주
ExterQual	외장재 품질 (Ex/Gd/TA/Fa)	범주(순서)
KitchenQual	주방 품질 (Ex/Gd/TA/Fa)	범주(순서)
CentralAir	중앙냉방 여부 (Y/N)	범주
SalePrice	판매가 (USD) — 예측 대상(Target)	수치

1.3 근거 자료 ① — SalePrice 상관 상위 feature

아래는 감축본 수치형 feature와 SalePrice의 피어슨 상관계수다. 상위 feature가 곧 과제 1의 시각화·과제 3의 핵심 입력 변수가 된다.

Feature	r (SalePrice)	Feature	r (SalePrice)
OverallQual	0.79	YearBuilt	0.52
GrLivArea	0.71	YearRemodAdd	0.51
GarageCars	0.64	Fireplaces	0.47
GarageArea	0.62	FullBath	0.56
TotalBsmntSF	0.61	TotRmsAbvGrd	0.53
1stFlrSF	0.61	LotArea	0.26

1.4 근거 자료 ② — 의도적으로 남긴 다중공선성 쌍

다음 쌍은 서로 강하게 상관되어 있어 함께 넣으면 회귀계수가 불안정해진다. **과제 2에서 이 쌍들을 직접 찾아 한쪽을 제거**하는 것이 목표다. (강사용 정답은 부록 B 참고)

공선 쌍	상관 r	중복 의미
GarageCars ↔ GarageArea	0.88	차고 규모(대수와 면적)
TotRmsAbvGrd ↔ GrLivArea	0.83	넓을수록 방이 많음
TotalBsmntSF ↔ 1stFlrSF	0.82	1층 넓이 ≈ 지하 넓이
YearBuilt ↔ YearRemodAdd	0.59	신축일수록 리모델링도 최근

2. 과제 구성과 배점

No	과제	핵심 도구	배점
1	주요 Feature 시각화	numpy·pandas·matplotlib·seaborn	15
2	공분산·다중공선성 진단과 제거	pandas·VIF	20
3	회귀모델 개발 (4가지+ 알고리즘)	Orange	20
4	시각 개체 5종	Power BI	15
5	주요 영향 요인 — SalePrice High	Power BI (Key Influencers)	10
6	HTML 대시보드 개발	HTML·CSS·JS	10
7	Ollama LLM 분석 채팅 연동	HTML·Ollama	10
	합계		100

3. 과제 상세

과제 1. 주요 Feature 시각화 [15점]

[목표] 감축 데이터셋에서 SalePrice와 관련이 큰 feature의 분포·관계를 시각적으로 파악한다.

[요구사항]

pandas로 CSV를 읽고(encoding='utf-8-sig'), df.info()·df.describe()로 구조와 기초통계를 확인한다.

- ① SalePrice 히스토그램(분포) + 왜도(skew) 값 표기
- ② OverallQual(품질 1~10)별 SalePrice 박스플롯
- ③ GrLivArea vs SalePrice 산점도 + 회귀선 (sns.regplot)
- ④ Neighborhood(지역)별 평균 SalePrice 막대그래프 (값 정렬)
- ⑤ (선택) 수치형 feature 상관 히트맵 (sns.heatmap)

```
import pandas as pd, numpy as np, seaborn as sns
import matplotlib.pyplot as plt
df = pd.read_csv('housePricing_reduced.csv', encoding='utf-8-sig')
print(df.info()); print(df.describe())
print('SalePrice 왜도:', round(df['SalePrice'].skew(), 2))
# 아래에 ①~④ 그래프 코드를 직접 작성
```

[제출물] .ipynb 또는 .py + 그래프 이미지, 각 그래프에 1~2줄 해석 코멘트

[힌트] SalePrice는 오른쪽으로 치우쳐 있다(왜도 양수). log 변환 전후 왜도를 비교하면 통계교재 3·4장(왜도·log변환)과 연결된다.

과제 2. 공분산 · 다중공선성 진단과 제거 [20점]

[목표] 중복 정보를 담은 feature를 찾아 제거해 회귀모델의 안정성을 높인다.

[요구사항]

- 수치형 feature의 상관행렬 df.corr() 과 공분산행렬 df.cov() 를 각각 구한다.
- 상관 히트맵을 그려 $|r| \geq 0.8$ 인 다중공선성 위험 쌍을 모두 찾는다 (최소 3 쌍).
- VIF(분산팽창인자)를 계산한다. $VIF > 10$ 이면 공선성 강함으로 판단.
- 공선 쌍 중 SalePrice와 상관이 낮은 쪽을 제거하고, 제거 전/후 VIF 변화를 표로 제시한다.

```
num = df.select_dtypes('number').drop(columns=['Id'])
corr = num.corr() # 상관행렬 (히트맵 대상)
cov = num.cov() # 공분산행렬
# VIF: 각 변수를 나머지로 회귀한 R²로 계산 (numpy 직접 구현 또는 statsmodels)
# VIF_i = 1 / (1 - R²_i) → VIF > 10 이면 제거 후보
```

[제출물] 히트맵, 제거 전/후 VIF 표, 제거한 feature 목록과 근거(왜 그쪽을 남겼는지)

[힌트] 이 데이터에는 의도적으로 공선 쌍이 포함되어 있다(1.4 표 참고). 통계교재 6장(다중공선성·VIF·히트맵)의 절차를 그대로 적용한다.

과제 3. Orange 회귀모델 개발 (4가지 이상 알고리즘) [20점]

[목표] 노코드 도구 Orange로 회귀 파이프라인을 구성하고 알고리즘 성능을 비교한다.

[요구사항]

- File 위젯으로 CSV 로드 → SalePrice 를 target(class) 변수로 지정.
- 과제 2 에서 공선 feature 를 제거하고 남긴 변수만 입력으로 사용 (Select Columns).
- 다음 중 4 가지 이상 연결: Linear Regression, Ridge/Lasso, Random Forest, Gradient Boosting, kNN, SVM, Tree, Neural Network.
- Test & Score 위젯(5-fold 교차검증)으로 R^2 ·RMSE·MAE 비교.
- Predictions / Scatter Plot 으로 실제값 vs 예측값을 시각화.

[제출물] Orange 워크플로우(.ows) 캡처, Test & Score 결과표, 최고 성능 모델과 선정 근거

[힌트] 평가지표 해석은 모델평가지표 교재 1부(MAE·MSE·RMSE· R^2) 참고. 일반적으로 트리·부스팅 계열이 선형보다 R^2 이 높게 나온다.

과제 4. Power BI 시각 개체 5종 [15점]

[목표] Power BI Desktop으로 데이터를 적재하고 대표 시각 개체 5종을 구성한다.

[요구사항] 서로 다른 시각 개체 5종을 만든다.

- ① 카드(Card): 평균 SalePrice, 주택 수 등 KPI
- ② 세로 막대: Neighborhood 별 평균 SalePrice
- ③ 산점도: GrLivArea vs SalePrice (OverallQual 로 색상 구분)
- ④ 꺾은선/영역: YearBuilt(건축연도)별 평균 SalePrice 추이
- ⑤ 슬라이서: OverallQual 또는 Neighborhood 필터

[제출물] .pbix 파일 또는 보고서 페이지 캡처 + 각 시각 개체 1줄 설명

[힌트] SalePrice_등급(High/Low) 계산 열을 미리 만들어 두면 과제 5로 바로 이어진다.

과제 5. 주요 영향 요인 — "SalePrice High"를 만드는 요인 [10점]

[목표] 주요 영향 요인(Key Influencers) 시각 개체로 고가 주택을 만드는 핵심 요인을 정량적으로 도출한다.

[요구사항]

- SalePrice 를 상/하로 구분하는 범주(예: 중앙값 또는 상위 25% 기준 High/Low)를 계산 열 또는 DAX 로 생성.
- 주요 영향 요인 시각 개체에서 '분석 대상 = SalePrice 등급', '설명 기준 = OverallQual·GrLivArea·Neighborhood·ExterQual 등' 지정.

- "SalePrice = High"가 되도록 하는 상위 영향 요인 3 가지 이상을 캡처하고 해석.

```
// DAX 계산 열 예시 (중앙값 기준 High/Low)
```

```
SalePrice_등급 =
```

```
IF ( 'data'[SalePrice] >= MEDIANX(ALL('data'),'data'[SalePrice]), "High", "Low" )
```

[제출물] Key Influencers 캡처 + 상위 요인 3가지와 영향 해석(예: OverallQual이 8↑일 때 High 확률 n 배)

[힌트] 품질(OverallQual)-면적(GrLivArea)이 최상위 요인일 가능성이 크다 — 과제 1:2의 상관 결과와 일치하는지 대조한다.

과제 6. HTML 대시보드 개발 [10점]

[목표] 순수 HTML/CSS/JS(또는 Chart.js 등)로 정적 웹 대시보드를 만든다.

[요구사항]

- 데이터를 CSV 또는 JSON 으로 포함/로드한다.
- KPI 카드 3 종(평균가·최고가·주택 수) + 차트 3 종 이상(지역별 평균가 막대, 면적-가격 산점도, 품질별 분포).
- 필터(지역 또는 품질 드롭다운) 1 개 이상으로 상호작용 제공.

[제출물] index.html(+ 필요 파일), 브라우저 캡처

[힌트] Chart.js CDN을 쓰면 빠르다. 색·레이아웃을 과제 4의 Power BI 보고서와 톤을 맞추면 일관성이 좋다.

과제 7. HTML 대시보드 + Ollama 언어모델 채팅 연동 [10점]

[목표] 로컬 LLM(Ollama)을 대시보드에 연결해 결과를 분석해 주는 채팅창을 구현한다.

[요구사항]

- 로컬에 Ollama 설치·실행 후 모델 다운로드 (예: ollama pull llama3.1 또는 gemma2).
- 대시보드에 채팅 UI(입력창 + 대화 영역)를 추가.
- 질문 시 대시보드 요약 통계(평균가·주요 요인 등)를 프롬프트에 함께 담아 Ollama API 로 요청하고 응답을 표시.
- 예시 질문: "이 지역에서 가격을 올리는 가장 큰 요인은?", "OverallQual 과 SalePrice 관계를 설명해줘."

```
// 브라우저에서 로컬 Ollama 호출 (stream:false로 단순화)
```

```
const res = await fetch('http://localhost:11434/api/chat', {
  method: 'POST', headers: {'Content-Type': 'application/json'},
  body: JSON.stringify({ model: 'llama3.1', stream: false,
    messages: [{role: 'system', content: '너는 주택가격 데이터 분석가다. 아래 요약을 근거로 답하라: '+summary},
      {role: 'user', content: userQuestion}] })
});
const data = await res.json(); answer = data.message.content;
```

[제출물] 채팅이 동작하는 대시보드, Ollama 실행/모델명 명시, 질의응답 캡처 2건 이상

[주의·CORS] 브라우저 호출 시 CORS 오류가 나면 OLLAMA_ORIGINS=* 환경변수로 Ollama를 실행한다. API 키·비밀번호는 코드에 넣지 말 것(로컬 전용).

4. 제출물 및 채점 기준

과제	제출물	채점 포인트	배점
1	노트북/스크립트 + 그래프	그래프 4종 완성·해석 코멘트	15
2	히트맵·VIF 표·제거 근거	공선 쌍 3+ 발견, 제거 후 VIF 개선	20
3	.ows·성능표	4+ 알고리즘 비교, 최적모델 근거	20
4	.pbix/캡처	시각 개체 5종·용도 설명	15
5	Key Influencers 캡처	상위 요인 3+ 해석	10
6	index.html·캡처	KPI+차트3+필터 동작	10
7	대시보드·Q&A 캡처	Ollama 응답·데이터 근거 반영	10

공통 감점: 제출 파일 누락, 한글 깨짐(encoding 미적용), 근거 없는 결과 서술.

제출 형식: 과제별 폴더(01_시각화 ~ 07_ollama)로 구분하여 압축(.zip) 제출. 각 폴더에 README 1장(무엇을·어떻게·결과 요약).

부록 B. 강사용 참고 (정답 힌트)

※ 아래는 강사 채점용 예상 결과다. 배포 시 이 페이지는 제외한다.

과제 2 — 예상 제거 대상

- GarageCars↔GarageArea ($r=0.88$): SalePrice 상관이 더 높은 GarageCars 유지, GarageArea 제거.
- TotRmsAbvGrd↔GrLivArea ($r=0.83$): GrLivArea 유지, TotRmsAbvGrd 제거.
- TotalBsmtSF↔1stFlrSF ($r=0.82$): TotalBsmtSF 유지, 1stFlrSF 제거(둘 다 유지도 허용, 근거 제시 시).
- 제거 후 VIF 는 대부분 5 이하로 안정화됨(감축 전 최대 $VIF \approx 5.3$, 쌍 제거 시 3 이하로 하락).

과제 3 — 예상 성능 경향

- Random Forest·Gradient Boosting: R^2 약 0.85~0.88 수준으로 최상위.
- Linear/Ridge: R^2 약 0.80 전후. kNN·SVM 은 스케일링 여부에 민감.

과제 5 — 예상 상위 영향 요인

- OverallQual(품질), GrLivArea(면적)가 'High' 확률을 가장 크게 끌어올림. 이어 Neighborhood 상위 지역, ExterQual=Ex/Gd.