

주택가격 데이터 분석 파이프라인 종합 실습과제 결과 보고서

Python 시각화 · 다중공선성 진단 · Orange 회귀 · Power BI · HTML 대시보드 · Ollama 연동
데이터셋: Ames Housing (housePricing_reduced.csv, 1,460행 · 16 feature + SalePrice)

(영등포8기) AX 자동화에서 LLM Agent까지 활용하는 AI 개발자 과정
2026. 07. 31.

0. 과제 개요 및 완료 현황

하나의 주택가격 데이터셋으로 데이터 탐색 → 다중공선성 제거 → 모델링 → BI 시각화 → 웹 대시보드 → LLM 연동까지 이어지는 엔드-투-엔드 분석 파이프라인을 구축하였다. 각 과제의 결과가 다음 과제의 입력으로 재사용되도록 구성하였다.

No	과제	핵심 도구	배점	결과 요약
1	주요 Feature 시각화	pandas·matplotlib·seaborn	15	그래프 5종 + 해석 (왜도 1.88 확인)
2	공분산·다중공선성 진단	pandas·statsmodels(VIF)	20	$ r \geq 0.8$ 쌍 3개 발견, 3개 변수 제거
3	Orange 회귀모델 4종	Orange3	20	5-fold CV, Gradient Boosting $R^2=0.840$ 최고
4	Power BI 시각 개체 5종	Power BI Desktop	15	카드·막대·산점도·꺾은선·슬라이서
5	주요 영향 요인 (High)	Power BI Key Influencers	10	CentralAir $\times 7.21$, GrLivArea $\times 5.59$ 등
6	HTML 대시보드	HTML·CSS·JS·Chart.js	10	KPI 3종 + 차트 3종 + 필터 2종 연동
7	Ollama LLM 채팅 연동	HTML·Ollama(gemma4:e2b)	10	필터 기준 통계를 프롬프트에 주입, Q&A 2건


전 과제에서 동일한 결론이 반복 검증되었다: 주택가격을 결정하는 최상위 요인은 품질(OverallQual, $r=0.79$)과 면적(GrLivArea, $r=0.71$)이며, 상관분석(과제 1~2), 회귀모델(과제 3), Key Influencers(과제 5), LLM 응답(과제 7)이 모두 같은 방향을 가리켰다.

과제 1. 주요 Feature 시각화 [15점]

목표 — 감축 데이터셋에서 SalePrice와 관련이 큰 feature의 분포·관계를 시각적으로 파악한다.


방법 — pandas로 CSV 로드(encoding=utf-8-sig) 후 df.info()·df.describe()로 구조 확인, seaborn/matplotlib으로 그래프 5종 작성. 각 그래프에 색 의미 해석 주석을 포함하였다.

① SalePrice 분포 — 왜도 1.88의 우편향




대다수 주택은 10~20만 달러대, 고가 주택이 긴 오른쪽 꼬리 형성 (log 변환 시 정규화 예상)

② 품질·③ 면적과 가격의 관계





OverallQual 상승 → 중앙값·분산 동반 상승 (단조 증가)



GrLivArea $r=0.71$ 선형 관계 + 이상치 2건(4,500sqft 이상 저가)

④ 지역별 평균가·⑤ 상관 히트맵



최고(NoRidge 33만\$)와 최저(MeadowV 10만\$) 간 3배 이상 격차

다중공선성 위험 쌍(0.88/0.83/0.82)이 진한 빨강으로 확인 → 과제 2로 연결

과제 2. 공분산 · 다중공선성 진단과 제거 [20점]

목표 — 중복 정보를 담은 feature를 찾아 제거해 회귀모델의 안정성을 높인다.


방법 — `df.corr()/df.cov()`로 상관·공분산행렬 산출, $|r| \geq 0.8$ 쌍 전수 탐색, statsmodels로 VIF 계산, 각 쌍에서 SalePrice와 상관이 낮은 쪽을 제거 후 VIF 재계산.

공선 쌍	r	제거 판단
GarageCars ↔ GarageArea	0.88	GarageCars($r=0.64$) 유지, GarageArea($r=0.62$) 제거
GrLivArea ↔ TotRmsAbvGrd	0.83	GrLivArea($r=0.71$) 유지, TotRmsAbvGrd($r=0.53$) 제거
TotalBsmtSF ↔ 1stFlrSF	0.82	TotalBsmtSF($r=0.613$) 유지, 1stFlrSF($r=0.606$) 제거

feature	VIF 제거 전	VIF 제거 후
GarageCars	5.31	1.86
GrLivArea	5.31	2.69
TotalBsmtSF	3.63	1.62

제거 전에도 $VIF < 10$ 으로 심각한 수준은 아니었으나, 제거 후 전 변수가 3 이하로 안정화

최종 입력 변수(9개 수치형): OverallQual, GrLivArea, GarageCars, TotalBsmtSF, FullBath, YearBuilt, YearRemodAdd, Fireplaces, LotArea (+ 범주형 4개) — 과제 3의 입력으로 재사용.




공선 변수 제거 후 상관 히트맵 — $|r| \geq 0.8$ 쌍이 모두 사라짐 (최대 0.63)

과제 3. Orange 회귀모델 개발 (4가지 알고리즘) [20점]

목표 — 노코드 도구 Orange로 회귀 파이프라인을 구성하고 알고리즘 성능을 비교한다.

방법 — File(reduced.csv, SalePrice=target) → Select Columns(과제 2 공선 변수 3개 Ignored) → Preprocess(Normalize) → ① Test and Score(전체 1,460행, 5-fold CV) / ② Data Sampler(80/20) → 모델 학습 → Predictions(20% 홀드아웃) → 모델별 산점도.



Orange 워크플로우 전체 캔버스 (pred_houseprice.ows)

모델	R^2 (Normalize)	R^2 (Discretize, 참고)	비고
Gradient Boosting	0.840	0.864	최고 성능 — 쌍대 비교 우위 확률 90%+
kNN	0.823	0.816	Normalize 적용 시 유일하게 상승 (거리 기반)
AdaBoost	0.811	0.836	
Linear Regression	0.803	0.830	

5-fold 교차검증 결과. 전처리를 Discretize→Normalize로 바꾸면 거리 기반 kNN만 상승 — 트리·선형 계열 하락은 이산화의 스무딩 효과 소실 때문으로 해석

최고 모델 선정 근거 — Gradient Boosting: ① R^2 0.840 최고, RMSE·MAE 최소 ② 쌍대 비교에서 모든 상대에 우위 확률 90% 이상 ③ 실제값 vs 예측값 산점도에서 대각선($y=x$) 주변 산포가 가장 작음(시각적 판독과 수치 지표 일치).

Test and Score - Orange

Cross validation
 Number of folds: 5
☒ Stratified
☐ Cross validation by feature
☐ Random sampling
 Repeat train/test: 10
 Training set size: 66 %
☒ Stratified
☐ Leave one out
☐ Test on train data
☐ Test on test data

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	12...	352...	20...	12.0...	11.507	0.803
AdaBoost	11...	344...	18...	11.0...	10.244	0.811
Gradient Boosting	10...	317...	17...	10.5...	9.801	0.840
kNN	11...	333...	19...	11.5...	10.991	0.823

Compare models by: Mean square error Negligible diff.: 0.1

	Linear Regression	AdaBoost	Gradient Boosting	kNN
Linear Regression		0.572	0.964	0.720
AdaBoost	0.428		0.791	0.562
Gradient Boosting	0.036	0.209		0.349
kNN	0.280	0.438	0.651	


Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

1460 | 4x1460 Stratification is ignored for regression

Test and Score 창 — 5-fold CV 성능표와 모델 쌍대 비교표

과제 4. Power BI 시각 개체 5종 [15점]

방법 — housePricing_reduced.csv 적재 후 카드(평균가·주택 수), 지역별 평균가 막대(정렬), GrLivArea-SalePrice 산점도(OverallQual 색상, Id 세부정보로 1채=1점), YearBuilt별 평균가 꺾은선, OverallQual 범위 슬라이서를 구성.



기본 상태 — 평균 180.92천\$, 1,460채

슬라이서 OverallQual 6~10 적용 — 평균 213.18천\$, 922채로 전체 연동


슬라이서 조작 시 카드·막대·산점도·꺾은선이 동시에 갱신되는 교차 필터링을 전/후 캡처로 검증. 평균가 180,921\$는 과제 1의 pandas 결과와 일치하여 적재·집계의 정확성을 교차 확인하였다.

과제 5. 주요 영향 요인 — "SalePrice High" [10점]


방법 — DAX 계산 열로 중앙값 기준 High/Low 등급 생성 후 Key Influencers 시각 개체에 분석 대상=SalePrice_등급(High), 설명 기준=주요 변수 9종을 지정.

순위	요인	High 확률	해석
1	CentralAir = Y	×7.21	냉방 보유 시 High 53% vs 미보유 7%. 단, 대부분 보유라 소수집단 신호
2	GrLivArea +525sqft	×5.59	면적 증가에 따라 연속적으로 상승 — 보편적 요인
3	OverallQual +1.38	×3.42	7등급 전후로 High 비율 급등하는 임계 구간 확인


이하 KitchenQual=Gd(×2.60), GarageCars 증가(×2.13), Neighborhood 상위지역(×2.0대) — 과제지 예상(품질·면적 최상위)과 부합하며 과제 1·2의 상관 순위와 일치



Key Influencers — 1위 CentralAir=Y ($\times 7.21$), 우측 상세: Y그룹 High 53% vs N그룹 7%




2위 GrLivArea ($\times 5.59$) 상세




3위 OverallQual ($\times 3.42$) 상세

과제 6. HTML 대시보드 개발 [10점]

방법 — 순수 HTML/CSS/JS + Chart.js v4로 정적 대시보드 구현. 데이터는 CSV→JSON 변환해 data.js로 내장(1,460행), Chart.js도 로컬 동봉하여 오프라인-file:// 환경에서 즉시 실행 가능. KPI 카드 3종(평균가·최고가·주택 수) + 차트 3종(지역별 평균가 막대, 면적-가격 산점도(품질=파랑 램프), 품질별 분포) + 필터 2종(지역·품질 드롭다운)이 전부 연동되며 라이트/다크 모드를 지원한다.



기본 상태 — 평균 \$180,921 · 최고 \$755,000 · 1,460채 (과제 1·4 결과와 일치)



NoRidge 필터 적용 — KPI \$335,295·41채로 갱신, 막대차트는 선택 지역만 강조(교차 필터링 구현)

과제 7. HTML 대시보드 + Ollama 채팅 연동 [10점]

방법 — 과제 6 대시보드에 채팅 UI를 추가. 질문 시 현재 필터 기준의 요약 통계(주택 수·평균/중앙/최고가·지역 상위 5·품질별 평균)와 과제 1~5의 사전 분석 결과(상관계수·Key Influencers 배수·모델 R^2)를 시스템 프롬프트로 구성해 로컬 Ollama (localhost:11434/api/chat, stream:false)로 요청. 모델: gemma4:e2b(로컬), CORS는 OLLAMA_ORIGINS=* 설정으로 해결.

데이터 분석 채팅 (Ollama)

질문하면 현재 필터 기준의 대시보드 요약 통계를 프론트엔드에 담아 로컬 Ollama로 보냅니다.

모델

gemma4:e2b (로컬)

☒ Ollama 연결됨 (설치 모델: gpt-oss:20b-cloud, gemma4:e2b)

안내
예시 질문 버튼을 누르거나 직접 질문을 입력하세요. 현재 적용된 필터(지역·품질)에 맞는 통계가 자동으로 모델에게 전달됩니다.

gemma4:e2b

제공된 요약 통계를 바탕으로 현재 필터 조건(지역=전체, 품질=전체)에 따른 데이터 분석 결과를 다음과 같이 요약합니다.

1. 데이터 개요 및 가격 분포
* **주택 수:** 총 1,460채의 주택 데이터가 존재합니다.
* **가격 분포:** 평균 판매 가격은 \$180,921이며, 중앙값은 \$163,000입니다. 최고가는 \$755,000에 달합니다.

2. 지역별 가격 비교
지역별 평균 가격 차이가 존재하며, 상위 지역이 평균 가격이 더 높게 나타납니다.

이 지역에서 가격을 올리는 가장 큰 요인은?

OverallQual과 SalePrice 관계를 설명해줘.

현재 필터 기준으로 데이터를 요약해줘.

주택가격 데이터에 대해 질문해보세요...

보내기

Q&A ① "현재 필터 기준으로 데이터를 요약해줘" — 주입된 통계(1,460채·평균 \$180,921·중앙값 \$163,000)를 근거로 답변

Q&A ② "이 지역에서 가격을 올리는 가장 큰 요인은?" — OverallQual($r=0.79$, $\times 3.42$)·CentralAir를 근거와 함께 제시

주택가치의 최상위 결정 요인은 품질(OverallQual)과 면적(GrLivArea)이다.

재사용 구조 — 과제 1의 히트맵이 과제 2의 진단 대상을 지목하고, 과제 2의 변수 선택이 과제 3의 입력이 되었으며, 과제 4의 계산 열이 과제 5의 분석 대상이, 과제 1~5의 결과 수치가 과제 7의 LLM 프롬프트 근거가 되는 엔드-투-엔드 구성을 실현하였다.

주요 학습 포인트 — ① 공분산은 스케일에 좌우되므로 다중공선성 진단에는 상관행렬을 사용 ② 상관 0.8대여도 VIF는 10 미만일 수 있음(전체 변수로 회귀한 설명력 기준) ③ 교차검증은 전체 데이터에, 홀드아웃 시각화는 학습에 쓰지 않은 20%에 적용 ④ 거리 기반 모델(kNN)만 정규화 수해, 트리 계열은 스케일 불변 ⑤ Key Influencers의 큰 배수가 곧 보편적 요인은 아님(이진 변수의 비대칭 분포 효과).